

AGENTES INTELIGENTES

El paradigma que unifica la Inteligencia Artificial moderna

Curso: Inteligencia Artificial | Profesor: Hugo Vega

Calero Falcón, Gonzalo Manuel · Huanacuni Gómez, Jean Carlos Josué


INTRODUCCIÓN

De trucos aislados a una teoría unificada

Durante décadas la IA fue vista como un collage de algoritmos sin relación entre sí: uno jugaba ajedrez, otro reconocía rostros, otro filtraba spam. Cada problema parecía requerir una teoría distinta.

1990

Stuart Russell (UC Berkeley) y Peter Norvig (Google Research) proponen el "agente racional" como estructura formal que unifica toda la disciplina.



UNA SOLA TEORÍA CONECTA TODO

CONCEPTO FUNDAMENTAL

¿Qué es un agente?

Cualquier entidad capaz de percibir su entorno mediante sensores y actuar sobre él mediante actuadores (Russell & Norvig, 2021). Rompe la pasividad del software tradicional.



PERCIBE

Capta el entorno con sensores: cámaras, datos, señales.



DECIDE

Delibera con modelos y objetivos internos.



ACTÚA


Ejecuta cambios reales mediante actuadores.

FUNCIONAMIENTO INTERNO

El ciclo continuo de todo agente

Desde el robot más simple hasta la nave espacial más sofisticada, el agente repite este bucle sin pausa. Un ejemplo cotidiano: un conductor en la Av. Javier Prado ve luces de freno adelante, calcula el riesgo y pisa el pedal, el auto frena y el ciclo empieza de nuevo.

- Percepción → secuencia acumulada de todo lo observado
- Decisión → evalúa objetivos y calcula probabilidades
- Acción → modifica el entorno y genera un nuevo estado



RACIONALIDAD

Racional no significa adivinar el futuro

Ser racional no es ser perfecto, omnisciente ni clarividente. Es tomar la mejor decisión posible con la evidencia disponible en el momento — aunque el resultado, por azar, salga mal.

OMNISCIENTE

Conoce el resultado real de cada acción antes de ejecutarla. Imposible en el mundo físico.

CLARIVIDENTE

Predice el futuro con certeza absoluta, violando el azar. Las máquinas no lo son.

RACIONAL

Decide con lo que sabe, maximizando su probabilidad de éxito. El estándar real y alcanzable.

Ejemplo: un peatón mira a ambos lados, la pista está despejada y cruza — perfectamente racional, aunque un vehículo imprevisto lo alcance. La racionalidad evalúa el razonamiento, no la suerte.

Los cuatro factores que definen lo racional

Russell y Norvig sostienen que la racionalidad de una acción depende de estos cuatro elementos evaluados en conjunto en cada instante:

01

Medida de rendimiento

El criterio de éxito, definido por el diseñador — nunca por la propia máquina.

02

Conocimiento previo

Lo que el sistema ya sabe del entorno antes de empezar a operar.

03

Historial de percepciones

Todo lo que los sensores han captado desde el encendido hasta hoy.

04

Acciones posibles

El repertorio real de movimientos que el agente puede ejecutar.

METODOLOGÍA DE DISEÑO

El marco REAS: la brújula del diseñador

Antes de escribir una línea de código, todo ingeniero debe responder cuatro preguntas. REAS (PEAS en inglés) estructura el diseño de cualquier agente, sin importar su complejidad.

R

Rendimiento

¿Cómo medimos el éxito del agente?

E

Entorno

¿En qué mundo opera y con quién interactúa?

A

Actuadores

¿Con qué "manos" modifica la realidad?

S

Sensores

¿Con qué "ojos y oídos" percibe su entorno?

ENTORNOS DE TAREAS

No todos los mundos son igual de difíciles

El ajedrez parece difícil para una persona, pero es un entorno fácil para una máquina: todo se ve, no hay azar y el mundo no cambia mientras piensa. Conducir en la ciudad es lo opuesto en las siete dimensiones.

Observable ● Parcialmente observable

Individual ● Multiagente

Determinista ● Estocástico

Episódico ● Secuencial

Estático ● Dinámico

Discreto ● Continuo

Conocido ● Desconocido



AJEDREZ

Fácil para la máquina: observable,
determinista, estático




TRÁFICO URBANO

El más difícil: parcial, estocástico,
dinámico y continuo

ARQUITECTURAS DE AGENTES

De la reacción simple al aprendizaje autónomo

Russell y Norvig clasifican los "cerebros" de los agentes en cinco niveles crecientes de sofisticación. Cada nivel añade una nueva capacidad cognitiva sobre el anterior.



ARQUITECTURAS 1 Y 2

Reflejo simple → reflejo con memoria

REFLEJO SIMPLE

"Si toco fuego, quito la mano"

Regla condición-acción sin memoria: reacciona solo a lo que percibe en este instante. Funciona en entornos simples y 100% observables (ej. sensor de luz en una cochera).

LIMITACIÓN: si el entorno es parcialmente observable, cae en bucles infinitos.

REFLEJO CON MODELO

"El mundo sigue ahí, aunque no lo vea"

Guarda un estado interno: cómo evoluciona el mundo por sí solo y cómo lo afectan sus propias acciones. Ejemplo: recordar que el camión en el punto ciego sigue ahí al cambiar de carril.

VENTAJA: decide bien incluso sin ver todo el escenario en tiempo real.

ARQUITECTURAS 3, 4 Y 5

Objetivos, utilidad y aprendizaje

Ejemplo Lima–Huancayo: varias rutas cumplen la meta de llegar, pero no todas son igual de rápidas, seguras o cómodas. Ahí es donde la utilidad marca la diferencia sobre solo "cumplir el objetivo".

BASADO EN OBJETIVOS

Planifica secuencias de acción hacia una meta.
Pregunta: "¿llegué o no?" Muy flexible: cambiar el destino no requiere reprogramar reglas.

BASADO EN UTILIDAD

Asigna una función matemática de satisfacción a cada estado posible. Sopesa velocidad vs. seguridad, costo vs. comodidad — resuelve trade-offs.

QUE APRENDE

Crítico + Elemento de Aprendizaje + Generador de Problemas. Mejora su comportamiento con la experiencia, sin reprogramación humana constante.

CASO PRÁCTICO DE INGENIERÍA

Agente fiscalizador de licitaciones (SEACE)

Cada año el Estado peruano licita decenas de miles de millones de soles en obras públicas. Los auditores humanos no dan abasto frente a cientos de miles de expedientes, y las redes de colusión se ocultan tras empresas de fachada.

- R** Detectar colusión con >90% de acierto y anticipar alertas 5 días antes de la firma.
- E** Base de datos SEACE (OCDS), RNP, SUNAT y Tribunal de Contrataciones.
- A** Alertas visuales, reportes explicables (SHAP) y bloqueo preventivo temporal.
- S** Montos ofertados, RUC, vínculos societarios e historial de sanciones.



91.6%

de precisión en la detección de fraude, frente al 64.2%
de las reglas manuales tradicionales

*Arquitectura híbrida: modelo de vínculos societarios + utilidad +
aprendizaje (Random Forest)*

RESULTADOS EXPERIMENTALES

El agente híbrido supera a los métodos tradicionales

Evaluación sobre 1,000 contratos históricos reales: precisión en la detección de fraude por enfoque tecnológico.



28.4% → 3.8%

Caída en falsas alarmas, evitando frenar compras legítimas y urgentes

Explicabilidad SHAP

El agente híbrido justifica cada alerta con causas concretas; las reglas manuales solo citan la norma fija violada.

SISTEMAS MULTIAGENTE (MAS)

Cooperar, competir y negociar

Ningún supercerebro centralizado es tan robusto como una red de especialistas autónomos que se comunican. Como en un hospital: triaje, cardiólogo y enfermería trabajan en conjunto sin que uno lo sepa todo.



COOPERACIÓN

Robots de rescate tras un sismo: uno detecta calor humano, otro perfora, un dron guía a los bomberos.



COMPETENCIA

Agentes de ciberseguridad defensivos contra atacantes automatizados que buscan vulnerabilidades.



NEGOCIACIÓN

Dos autos autónomos en un cruce estrecho negocian en milisegundos quién cede el paso.

Protocolo FIPA-ACL: los agentes se comunican con actos de habla estandarizados — INFORM, REQUEST, PROPOSE, ACCEPT/REJECT-PROPOSAL.

EL PRESENTE DE LA IA

De responder preguntas a ejecutar tareas

Los chatbots devolvían texto y dejaban toda la acción al usuario. Hoy, los modelos de lenguaje usan herramientas (tool-use) para actuar directamente: consultar bases de datos, ejecutar código y operar software como lo haría una persona.



"Revisa los gastos del mes pasado, detecta facturas sospechosas mayores a S/ 5,000 y redacta un correo al contador pidiendo aclaraciones."

ÉTICA Y SEGURIDAD

La máquina propone. El humano decide.

El poder de acción autónoma trae riesgos evidentes: un agente de compras mal calibrado podría ordenar mil laptops innecesarias; un agente hospitalario podría errar una dosis por un fallo de sensor.



HUMAN-IN-THE-LOOP

Para decisiones de alto riesgo financiero, médico, legal o de seguridad física, el agente solo investiga, planifica y propone. La ejecución final exige siempre la firma de un humano responsable.



ADVERTENCIAS DE LA INDUSTRIA

En 2026, laboratorios como Anthropic y OpenAI advirtieron sobre agentes maliciosos capaces de escanear servidores y ejecutar ataques de ransomware a velocidad sobrehumana.

Ex investigadores de laboratorios de vanguardia han pedido salvaguardas técnicas estrictas antes de que la autonomía conectada a internet supere el control humano.

GOBERNANZA EN EL PERÚ

Ley N.° 31814 y Ley N.° 32069

El Estado peruano ha dado pasos firmes para proteger a los ciudadanos frente a la IA sin frenar la innovación tecnológica del país.



LEY N.° 31814

Promueve el uso de la Inteligencia Artificial para el desarrollo económico y social del país. Bajo la rectoría de la Secretaría de Gobierno y Transformación Digital (PCM), prohíbe que un sistema autónomo vulnere la privacidad, discrimine algorítmicamente o actúe sin auditoría humana en servicios esenciales.



LEY N.° 32069

Ley General de Contrataciones Públicas: promueve tecnologías digitales y análisis inteligente de datos para transparentar el mercado estatal. Garantiza que los agentes fiscalizadores protejan los recursos públicos y que las MYPE compitan con igualdad de oportunidades.

Conclusiones

1

El agente unifica la IA moderna

Percibir, deliberar y actuar es la estructura formal que da sentido a toda la disciplina.

2

El entorno define la arquitectura

REAS y las siete dimensiones son la herramienta indispensable para diseñar sin errores.

3

La colaboración distribuida gana

Los sistemas multiagente son más robustos y eficientes que un cerebro centralizado.

4

La autonomía exige gobernanza

Human-in-the-Loop y marcos como la Ley 31814 protegen a las personas sin frenar la innovación.



GRACIAS