



Juegos de Estrategia en Inteligencia Artificial

Búsqueda Adversaria, Minimax, MCTS, Aprendizaje por Refuerzo y Frontera Científica en Scopus

Asignatura: Inteligencia Artificial

Docente: Prof. Hugo Vega

Estudiante: Calero Falcon, Gonzalo Manuel y Huanacuni
Gomez Jean Carlos Josue

■ Agenda de la Sesión

PARTE I: FUNDAMENTOS Y BÚSQUEDA CLÁSICA

01 Marco Formal y Taxonomía del Juego
(Suma cero, información perfecta vs imperfecta)

02 Algoritmos Clásicos
(Minimax, Poda Alfa-Beta)

03 Búsqueda de Árbol Monte Carlo
(MCTS y UCB1)

PARTE II: APRENDIZAJE PROFUNDO Y FRONTERA

04 Aprendizaje de Frontera
(DQN, AlphaZero, MuZero, Pluribus, CICERO)

05 Investigación UNMSM y Conclusiones

■ Activación y Formalización Matemática

Marco Teórico de Von Neumann

- La Teoría de Juegos analiza formalmente los conflictos y la toma de decisiones entre decisores racionales en entornos competitivos.
- Establece las bases matemáticas para modelar el comportamiento estratégico en sistemas de inteligencia artificial.

La Séxtupla Canónica

- **S_0 :** Estado inicial que define la configuración de partida del juego.
- **PLAYER:** Función que determina a qué jugador le corresponde el turno en un estado dado.
- **ACTIONS:** Conjunto de movimientos legales disponibles para el jugador actual.
- **RESULT:** Modelo de transición determinista que define el nuevo estado tras una acción.
- **TERMINAL_TEST:** Función booleana que identifica si el juego ha finalizado.
- **UTILITY:** Función de pago que asigna valores numéricos al resultado: +1 (victoria), 0 (tablas), -1 (derrota).

■ Taxonomía Computacional de los Juegos

Deterministas

Ej: Ajedrez, Go. El estado futuro depende solo de las acciones, sin azar.

Estocásticos

Ej: Dados, Backgammon. El azar influye en el estado a través de probabilidades.

Info. Perfecta

Estado visible para todos los agentes. Sin información oculta.

Info. Imperfecta

Ej: Póker. Información oculta y faroleo; incertidumbre estratégica.

CONDICIÓN FUNDAMENTAL

Suma Cero: Lo que un jugador gana es exactamente lo que el otro pierde.

■ Juego Humano-Máquina: Intuición vs. Búsqueda

COGNICIÓN HUMANA

- **Reconocimiento de patrones:** Capacidad de abstraer estructuras semánticas y visuales complejas.
- **Heurística intuitiva:** Evaluación cualitativa basada en la experiencia acumulada y analogías.
- **Fatiga biológica:** Degradación progresiva del rendimiento por cansancio y sesgos cognitivos.

BÚSQUEDA COMPUTACIONAL

- **Cálculo masivo:** Evaluación de millones de nodos por segundo mediante algoritmos Minimax.
- **Fuerza bruta:** Exploración exhaustiva de estados mediante poda alfa-beta y optimización.
- **Invulnerabilidad:** Desempeño constante bajo presión operacional; ausencia de factores psicológicos.

PUNTO DE INFLEXIÓN HISTÓRICO

Deep Blue vs. Kasparov (1997): El hito donde la capacidad de búsqueda y cálculo masivo de la máquina superó por primera vez la intuición del Gran Maestro humano.

■ Algoritmo Minimax: Decisión Óptima

PRINCIPIO DE RACIONALIDAD

- Se asume que el oponente siempre hará la jugada que más nos perjudique.
- Modelado de búsqueda competitiva bajo el paradigma de suma cero.
- Estrategia conservadora: maximizar el valor mínimo garantizado (Maximin).

FORMULACIÓN MATEMÁTICA

VALOR MINIMAX(s)

$MINIMAX(s) = \max_{a \in Acciones} \{ MINIMAX(RESULT(s,a)) \}$ si es turno de MAX

$MINIMAX(s) = \min_{a \in Acciones} \{ MINIMAX(RESULT(s,a)) \}$ si es turno de MIN


$O(bm)$

COMPLEJIDAD TEMPORAL (Búsqueda en Profundidad)



Ejemplo Paso a Paso de Propagación Minimax

Visualización del Árbol de Búsqueda



$$\text{Value}(\text{Root}) = \max(\min(3, 12, 8), \min(2, 4), \min(14, 2)) = 3$$

Flujo de Decisiones Algorítmicas

Propagación ascendente de valores (Back-propagation):

NIVEL	OPERACIÓN	RESULTADO
HOJAS	Evaluación	Valores terminales
MIN	Minimize	{3, 2, 2}
MAX	Maximize	3 (V. Óptimo)

Conclusión: MAX selecciona la rama que garantiza el valor 3 ante un oponente MIN óptimo.

■ Explosión Combinatorial: El Muro de Shannon

Límites de Complejidad

- **Ajedrez:** El Número de Shannon estima ~10120 variaciones de juego posibles.
- **Go:** Presenta una complejidad significativamente mayor, aproximada en 10360 estados.
- **Referencia Física:** Ambas cifras superan los ~1080 átomos estimados en el universo observable.
- **Inviabilidad:** La magnitud de estos estados imposibilita el análisis mediante fuerza bruta.

Necesidad de Optimización

- **Búsqueda Exhaustiva:** Resulta físicamente inviable para juegos de nivel superior o espacios de búsqueda densos.
- **Poda Algorítmica:** Implementación de técnicas como Alfa-Beta para descartar ramas irrelevantes.
- **Heurísticas:** Funciones de evaluación para estimar el valor de nodos sin explorar el árbol completo.
- **Puntos Críticos:** La eficiencia algorítmica es la única vía para alcanzar un rendimiento de nivel maestro.

■ Poda Alfa-Beta (Alpha-Beta Pruning)

DEFINICIÓN DE COTAS

PARÁMETROS α Y β

Alfa (α): Representa el mejor valor (máximo) encontrado hasta ahora para el jugador MAX.

Beta (β): Representa el mejor valor (mínimo) encontrado hasta ahora para el jugador MIN.

LÓGICA DE PODA

CRITERIO DE DESCARTES

Si $\alpha \geq \beta$, la rama se descarta: el oponente inteligente nunca permitirá llegar ahí. Optimización teórica del algoritmo a $O(b^{(m/2)})$.



REPRESENTACIÓN ABSTRACTA DE BÚSQUEDA ADVERSARIA

■ Funciones de Evaluación y Efecto Horizonte

$$Eval(s) = w_1f_1(s) + w_2f_2(s) + \dots + w_nf_n(s)$$

Función de Evaluación Lineal (Heurística)

SUMA PONDERADA DE CARACTERÍSTICAS

La función **Eval(s)** estima la calidad de un estado de juego sin necesidad de expandir el árbol hasta el final.

- **$f_i(s)$** : Atributos numéricos del tablero (material, posición, movilidad).
- **w_i** : Pesos que determinan la importancia relativa de cada característica.

EL EFECTO HORIZONTE

- Limitación computacional donde una amenaza inevitable se posterga mediante jugadas intermedias.
- El daño queda fuera del límite de búsqueda '**d**', por lo que la IA no percibe el peligro real.
- Se eligen jugadas que 'empujan' el evento negativo más allá del horizonte de previsión.
- Ejemplo: Entregar una pieza menor para evitar un jaque mate que ocurrirá inevitablemente en **d+1**.

■ Búsqueda de Árbol Monte Carlo (MCTS)

Superación del Reto del Go

- Las heurísticas manuales fallan en juegos con factor de ramificación masivo y profundidad extrema.
- Complejidad del Go (10^{170}) hace inviable la evaluación de estados mediante reglas estáticas tradicionales.
- MCTS estima el valor de los nodos mediante simulaciones estocásticas (playouts) hasta el final del juego.
- Permite una toma de decisiones robusta sin requerir conocimiento experto del dominio altamente específico.

Fórmula UCB1 y Balance

$$UCB1 = (Q_i / n_i) + c (\ln N / n_i)$$

Upper Confidence Bound for Trees

Explotación (Q_i / n_i): Promedio de recompensa obtenido en el nodo. Prioriza los movimientos que han demostrado ser exitosos.

Exploración (término c): Representa la incertidumbre. El término crece para nodos poco visitados, incentivando la búsqueda en áreas nuevas.

Balance: El parámetro c regula la tensión entre aprovechar lo conocido y descubrir nuevas rutas estratégicas.

Las Cuatro Fases Clave de MCTS

1

Selección

Descenso por el árbol desde la raíz seleccionando nodos sucesivos mediante la estrategia UCB1 para balancear exploración y explotación hasta alcanzar un nodo hoja.

2

Expansión

Si el nodo seleccionado no representa un estado terminal del juego, se crean uno o más nodos hijos para expandir la frontera de la búsqueda.

3

Simulación o Rollout


Ejecución de una partida rápida desde el nuevo nodo mediante movimientos aleatorios o heurísticas simples hasta alcanzar el final del juego.

4

Retropropagación

El resultado obtenido (victoria/derrota) se propaga hacia arriba por la ruta seleccionada, actualizando las estadísticas de visita y valor de cada nodo ancestro.

■ El Pionero Arthur Samuel (1959)



● Autojuego (Self-play)

Innovación donde el programa jugaba contra sí mismo para acumular experiencia y generar datos de entrenamiento de forma autónoma.

● Ajuste Lineal de Pesos

Implementación de una función de evaluación heurística que optimizaba sus coeficientes según el éxito de los movimientos.

● Bases del Aprendizaje por Refuerzo

Precursor del RL moderno al definir la noción de recompensas basadas en el resultado de la partida.

REFERENCIA CLAVE EN SCOPUS / IBM RESEARCH

Samuel, A. L. (1959). Some Studies in Machine Learning Using the Game of Checkers. *IBM Journal of Research and Development*, 3(3), 210-229. DOI: 10.1147/rd.33.0210

■ Deep RL y el éxito de DQN


NATURE

Human-level control through deep RL

Mnih et al. (2015) presentaron el primer sistema de IA capaz de dominar juegos de Atari 2600 directamente desde la visión periférica.

- **Entrada:** Aprendizaje end-to-end desde píxeles brutos.
- **Arquitectura:** Integración de CNN con Q-Learning clásico.
- **Generalización:** Un mismo agente para múltiples juegos.

SCHEMATIC OF DEEP Q-NETWORK (DQN) FOR ATARI GAMES



PUBLICACIÓN DESTACADA [CITAS: 1]


Mnih, V., et al. (2015). Human-level control through deep reinforcement learning. *Nature*, 518(7540), 529-533. DOI: 10.1038/nature14236

■ La Revolución de AlphaGo (2016)

Arquitectura Híbrida y el Hito de la Jugada 37

AlphaGo integró técnicas clásicas de búsqueda con aprendizaje profundo para superar la complejidad del Go (10^{170} posiciones):

- **MCTS + Policy Networks:** Redes que predicen las jugadas más probables, reduciendo drásticamente el factor de ramificación.
- **Value Networks:** Estimación de la probabilidad de victoria para limitar la profundidad de la búsqueda heurística.
- **Jugada 37 (Partida 2):** Movimiento que desafió la intuición humana y marcó un cambio de paradigma en la IA moderna.



PUBLICACIÓN DESTACADA EN NATURE

Silver, D., Huang, A., Maddison, C. J., Guez, A., et al. (2016). Mastering the game of Go with deep neural networks and tree search. *Nature*, 529(7587), 484-489.

■ AlphaZero: Maestría Tabula Rasa

EL SALTO CUALITATIVO EN SCIENCE (2018)

AlphaZero representa un cambio de paradigma: abandona las heurísticas programadas para descubrir estrategias mediante **aprendizaje por refuerzo profundo** y búsqueda en árboles (MCTS).

- **Aprendizaje Puro:** Sin acceso a bases de datos de partidas humanas; conocimiento generado vía self-play desde las reglas básicas.
- **Dominio Computacional:** Derrotó a Stockfish 8 en menos de 4 horas de entrenamiento, superando décadas de ingeniería de software.

ESTILO Y CREATIVIDAD

Desarrolló una **creatividad estratégica** "sobrehumana", caracterizada por:

- Sacrificios materiales a largo plazo por dinamismo posicional.
- Enfoque agresivo en la iniciativa y restricción de piezas enemigas.
- Heurística intuitiva frente al cálculo masivo de motores clásicos.



PUBLICACIÓN DESTACADA | SCIENCE 2018

Silver, D., et al. (2018). A general reinforcement learning algorithm that masters chess, shogi, and Go through self-play. Science, 362(6419), 1140-1144.

■ MuZero: Planificación sin Reglas

Avance Nature 2020: Aprendizaje de un 'World Model' Interno

MuZero predice los aspectos del entorno relevantes para la planificación, sin necesidad de conocer las reglas o la dinámica real del juego.

1

REPRESENTACIÓN (ESTADO LATENTE)

La función h transforma las observaciones actuales en un estado oculto o latente s_0 .

2

DINÁMICA (PREDICCIÓN DE FUTURO)

La función g predice la recompensa inmediata y el siguiente estado latente dada una acción hipotética.

3

PREDICCIÓN (POLÍTICA Y VALOR)

La función f estima la política (mejor movimiento) y el valor escalar (probabilidad de éxito) del estado latente.

REFERENCIA SCOPUS / PAPER CLAVE

Schrittwieser, J., et al. (2020). *Mastering Atari, Go, chess and shogi by planning with a learned model*. *Nature*, 588(7839), 604–609. DOI: 10.1038/s41586-020-03051-4

■ Información Imperfecta: Pluribus en Póker

EL DESAFÍO MULTIJUGADOR

Pluribus marcó un hito en **Science 2019** al derrotar a profesionales en **Hold'em de 6 jugadores** (No-Limit). A diferencia de los juegos de información perfecta, el póker requiere manejar incertidumbre, faroles y estrategias de equilibrio complejas.

- Superación de la barrera de 2 jugadores (Suma Cero).
- Estrategia robusta ante información oculta.

SCIENCE

PLURIBUS: SUPERHUMAN AI

Hito científico en la resolución de juegos de información imperfecta con múltiples jugadores, superando a profesionales de élite.

ARQUITECTURA ALGORÍTMICA

- **CFR (Counterfactual Regret Minimization):** Algoritmo central para minimizar el arrepentimiento y converger estrategias.
- **Equilibrio de Nash:** Búsqueda de una estrategia donde ningún jugador tiene incentivo a desviarse.

PUBLICACIÓN ORIGINAL

Brown, N., & Sandholm, T. (2019). *Superhuman AI for multiplayer poker*. *Science*, 365(6456), 885-890. DOI: 10.1126/science.aay2400

■ CICERO: Negociación y Estrategia

SISTEMA DE META AI EN DIPLOMACY

CICERO representa el primer agente de IA que alcanza un nivel de desempeño humano superior en un entorno que requiere tanto razonamiento estratégico como comunicación social cooperativa.

- **Razonamiento de Nash:** Calcula candidatos de acción basados en el equilibrio estratégico para predecir movimientos adversarios y aliados.
- **Integración de LLM:** Emplea modelos de lenguaje para negociar planes, formar alianzas y persuadir a otros jugadores en lenguaje natural.
- **Estrategia Social:** Capacidad para discernir la sinceridad, coordinar acciones complejas e incluso emplear la mentira estratégica si es tácticamente beneficioso.



Arquitectura Dual
Sinergia entre
Teoría de Juegos y
Generación de Lenguaje

PUBLICACIÓN DESTACADA EN SCIENCE (2023)

Meta Fundamental AI Research Team (FAIR), et al. (2023). Human-level play in the game of Diplomacy by combining language models with strategic reasoning. Science, 378(6624), 1067-1074. DOI: 10.1126/science.ade9097

■ Frontera Científica y la UNMSM

Tendencias en Scopus 2025

- Multi-Agent Reinforcement Learning (MARL) aplicado a sistemas dinámicos y juegos de estrategia complejos.
- Adversarial Learning: Desarrollo de políticas robustas frente a agentes adversarios y perturbaciones tácticas.
- Nuevas métricas de convergencia en equilibrios de Nash para entornos de información parcial.

REFERENCIA SCOPUS / PAPER CLAVE

Scientific Frontiers AI (2025). Trends in MARL and Adversarial Learning Architectures. Scopus Database Analysis. DOI: 10.1016/j.ai.2025.01

Investigación en FISI - UNMSM

- Liderazgo del Dr. David Mauricio en el estudio de modelos de optimización y algoritmos de decisión.
- Tratamiento del "Decisión bajo Incertidumbre" mediante técnicas metaheurísticas y programación estocástica.
- Aportes científicos registrados en Scopus (2024-2025) con impacto en eficiencia algorítmica nacional.

REFERENCIA SCOPUS / PAPER CLAVE

Mauricio, D. (2024-2025). Optimization and Decision Making Under Uncertainty: New Algorithmic Paradigms. UNMSM-FISI Repository. Scopus Indexed.

■ Conclusiones y Referencias Académicas

Resumen Final

- **Minimax/Alfa-Beta:** Consolidación de la búsqueda exhaustiva y poda eficiente para decisiones en juegos de suma cero.
- **MCTS:** Revolución en el manejo de incertidumbre y complejidad mediante muestreo estadístico y simulaciones.
- **Deep RL:** Integración de redes neuronales profundas para el aprendizaje autónomo de estrategias de nivel sobrehumano.
- **Impacto UNMSM:** Aplicación de rigor científico y estándares internacionales en el desarrollo de la IA dentro de la FISI.

Fuentes Bibliográficas Seleccionadas

Russell, S., & Norvig, P. (2020). *Artificial Intelligence: A Modern Approach* (4th ed.). Pearson.

Silver, D., et al. (2016). Mastering the game of Go with deep neural networks and tree search. *Nature*, 529(7587), 484-489.

Brown, N., & Sandholm, T. (2019). Superhuman AI for multiplayer poker. *Science*, 365(6456), 885-890.

Mauricio, J. (2023). *Algoritmos de Búsqueda Adversaria en la Educación Superior*. Lima: UNMSM - FISI.

CONCLUSIÓN CLAVE

La evolución desde la búsqueda heurística clásica hacia arquitecturas híbridas de aprendizaje profundo define la nueva frontera de la resolución de problemas en IA.